Comparación de ResNet50, EfficientNet-B0 y Swin-T en ISIC 2019 bajo un protocolo común

Pregunta: cómo se ordenan tres arquitecturas cuando reciben exactamente el mismo presupuesto

---

Santiago Valdés Uriarte

15 de octubre de 2026

Maestría en Inteligencia Artificial y Ciencia de Datos, Universidad Panamericana
Aprendizaje Profundo, proyecto final

Mismo protocolo para las tres arquitecturas: lo único que cambia es el modelo

Datos: ISIC 2019

- 25,331 imágenes, 8 clases
- Desbalance de 54 a 1 (NV contra DF)
- Partición 70/15/15 agrupada por lesión: 17,735 / 3,798 / 3,798
- Evaluación externa: test oficial sin UNK, 6,191 imágenes

Hardware

RTX 5070 Ti Laptop, 12 GB de VRAM
Core Ultra 9, Ubuntu en WSL2

Modelos de timm, pesos de ImageNet

	Parámetros (M)	GMACs
ResNet50	23.5	4.1
EfficientNet-B0	4.0	0.4
Swin-T	27.5	4.5

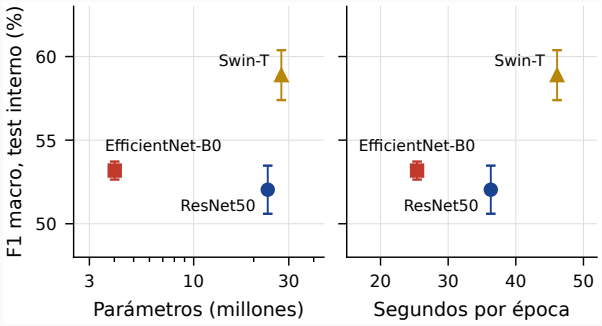
Hiperparámetros compartidos

- 224 px, AdamW con lr 10^{-4}
- 15 épocas, early stopping sobre F1 macro
- Pérdida ponderada por frecuencia inversa
- 3 semillas por modelo: 9 corridas

Swin-T gana en todas las métricas; en F1 macro por 5.7 pp, casi cuatro veces el ruido entre semillas

	ResNet50	EffNet-B0	Swin-T
Test interno (3,798)			
F1 macro	52.0 ± 1.4	53.2 ± 0.5	**58.9** ± 1.5
Exact. bal.	56.6 ± 1.7	54.1 ± 0.9	**57.7** ± 0.9
Exactitud	65.6 ± 0.4	68.4 ± 0.3	**73.4** ± 0.8
AUROC	90.7 ± 0.6	91.8 ± 0.1	**94.2** ± 0.2
Test oficial (6,191)			
F1 macro	51.6 ± 0.9	53.0 ± 1.2	**58.5** ± 1.5

En porcentaje. Media ± desviación de las semillas 0, 1 y 2.



F1 macro del test interno contra parámetros (escala log) y segundos por época.

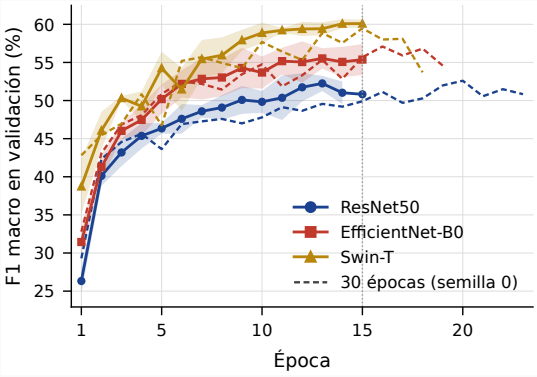
Entre las CNN el orden depende de la métrica: ResNet50 gana en exactitud balanceada.

Swin-T rinde más por época y EfficientNet-B0 cuesta menos; ResNet50 queda dominado

	ResNet50	EffNet-B0	Swin-T
Parámetros (M)	23.5	**4.0**	27.5
GMACs	4.1	**0.4**	4.5
s/época	36.3	**25.4**	46.1
Min por corrida	8.6	**6.9**	11.0
VRAM (GiB)	1.8	**1.4**	2.6
Inferencia (img/s)	1,770	**3,096**	1,189
Mejor época	10.7	12.3	13.0

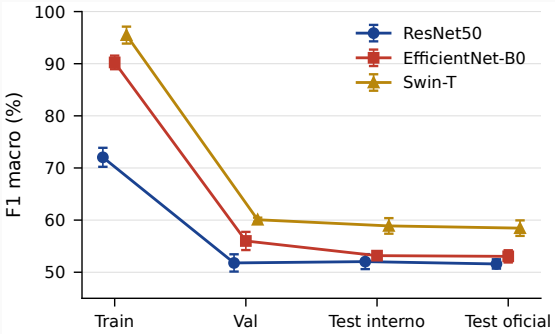
Media de 3 semillas. En negritas, el menor costo. Batch 32, bf16.

ResNet50 está subajustado: F1 macro en train de 72.0, contra 90.2 y 95.5.



F1 macro de validación por época. Continua: media de 3 semillas. Punteada: semilla 0 con 30 épocas.

El F1 macro se sostiene en el test oficial; las otras métricas caen de 1.7 a 4.3 pp



F1 macro en train (sin augmentation), validación, test interno y test oficial.

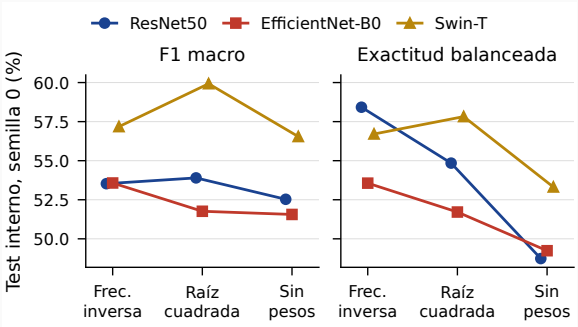
Del interno al oficial: F1 macro, 0.4 pp o menos; exactitud balanceada, exactitud y AUROC, de 1.7 a 4.3 pp.

	F1 macro		
Ensemble	Interno	Oficial	GMACs
Swin-T (media)	58.9	58.5	4.5
ResNet50 (media)	52.0	51.6	4.1
Arquitecturas	59.3	58.2	9.0
3 semillas **Swin-T**	**60.5**	**60.5**	13.5
3 semillas **EffNet-B0**	56.7	56.9	1.2

Promedio de softmax. Arquitecturas: semilla 0 de cada modelo.

Mezclar arquitecturas no supera a 3 semillas de Swin-T; 3 EfficientNet-B0 superan a ResNet50 con menos cómputo.

Hipótesis descartada: sin pesos sube la exactitud y se desploma la exactitud balanceada



Test interno, semilla 0 de cada modelo.

Hipótesis previa: la frecuencia inversa deprime el F1 macro. Sin pesos debía subir, y baja en los tres.

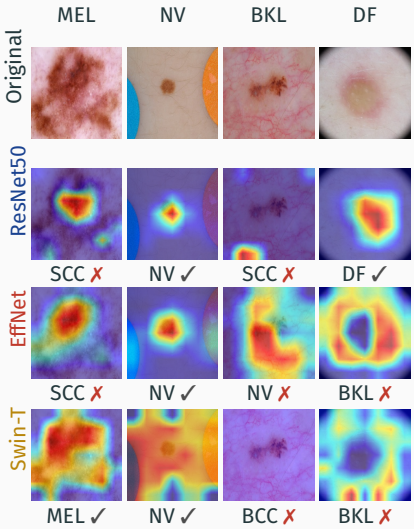
ResNet50, semilla 0

	Inversa	Raíz	Sin pesos
F1 macro	53.5	53.9	52.5
Exact. bal.	58.4	54.8	**48.7**
Exactitud	65.9	70.1	72.7
F1 macro oficial	51.9	51.5	46.6
DF precisión	40.4	27.9	75.0
DF recall	52.8	33.3	**16.7**

Inversa: $1/n$ (protocolo). Raíz: $1/\sqrt{n}$. En porcentaje.

Sin pesos deja de predecir las clases raras.

Grad-CAM permite comparar las dos CNN; en Swin-T falla el método, no el modelo



CNN: los mapas caen sobre la lesión en la mayoría de los casos y se comparan entre sí.

Swin-T: bloques en cruz que siguen las ventanas de 7×7. En el NV acierta con un mapa que cubre casi toda la imagen; en el BKL sale vacío, pues el ReLU anula un gradiente negativo.

Lectura: Grad-CAM se diseñó para mapas convolucionales; en Swin-T la capa objetivo es una normalización.

Clase real como objetivo, semilla 0. Bajo cada mapa, la clase predicha. 4 de las 16 imágenes fijas.

Swin-T si manda el desempeño, EfficientNet-B0 si manda el costo; ResNet50 no conviene con este protocolo

Recomendación

1. Sin límite de cómputo: **Swin-T** (58.9; 58.5 en el oficial)
2. Hardware modesto: **EfficientNet-B0** (0.4 GMACs, 3,096 img/s)
3. Intermedio: 3 EfficientNet-B0 (56.7 con 1.2 GMACs)

Limitaciones

1. Nivel bajo la literatura: 224 px, augmentation suave, 15 épocas
2. Un protocolo común no es el óptimo de cada arquitectura
3. DF y VASC con 36 y 38 imágenes de test

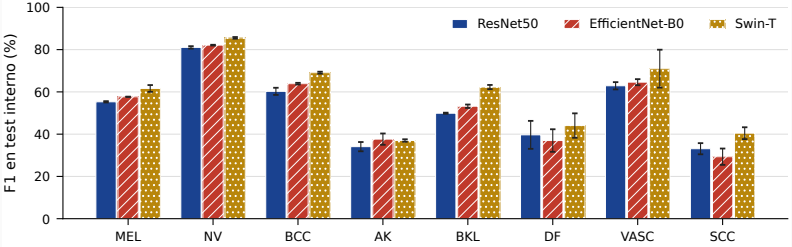
Trabajo futuro

1. Tasa de aprendizaje por arquitectura
2. Mayor resolución y preentrenamiento autosupervisado
3. Attention rollout para Swin-T

Código, configuraciones y particiones: `github.com/Valdes10U/isic2019-benchmark`

Material de respaldo

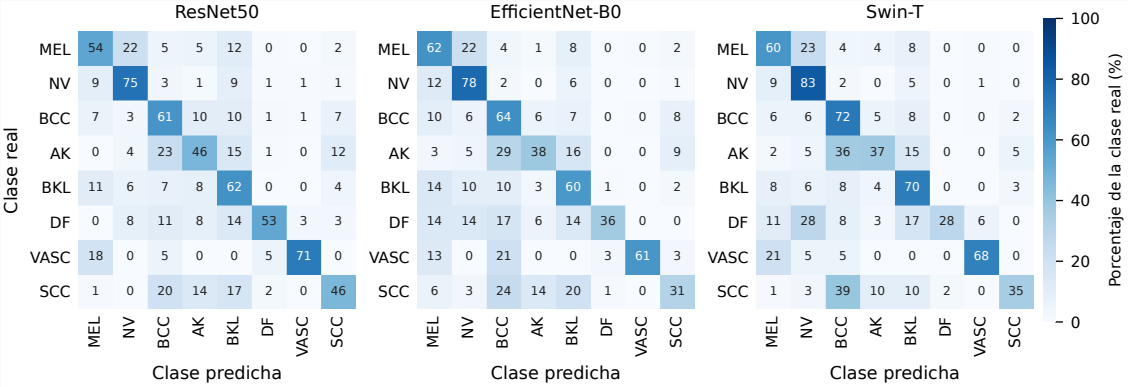
Swin-T es el mejor en 7 de 8 clases; AK, SCC y DF son las más difíciles para los tres



	MEL	NV	BCC	AK	BKL	DF	VASC	SCC
ResNet50	55.3	81.1	60.3	34.1	49.9	39.7	62.9	33.1
EfficientNet-B0	57.7	82.1	63.9	**37.6**	53.2	37.0	64.6	29.3
Swin-T	**61.6**	**85.6**	**69.1**	37.0	**62.3**	**44.1**	**71.0**	**40.5**
Soporte	678	1,929	499	130	394	36	38	94

F1 por clase en el test interno, media de 3 semillas; la desviación está en las barras de error.

Buena parte del error viene de AK y SCC confundidas con BCC, y de MEL confundido con NV



Test interno, semilla 0, porcentaje de cada clase real (las filas suman 100). Entre 23 y 36 % de las AK y entre 20 y 39 % de los SCC terminan en BCC; entre 22 y 23 % de los MEL, en NV.

En el test oficial la precisión de las minoritarias sube en 11 de 12 casos; el recall de VASC cae

	Precisión		Recall	
	Interno	Oficial	Interno	Oficial
DF (36 / 91 imágenes)				
ResNet50	36.2	46.2	45.4	50.2
EffNet-B0	39.0	53.3	36.1	45.8
Swin-T	56.5	78.9	37.0	49.5
VASC (38 / 104 imágenes)				
ResNet50	58.2	64.2	68.4	48.4
EffNet-B0	64.4	72.1	64.9	41.0
Swin-T	74.5	83.8	68.4	45.8

	Precisión		Recall	
	Interno	Oficial	Interno	Oficial
SCC (94 / 165 imágenes)				
ResNet50	26.7	28.1	44.7	38.6
EffNet-B0	29.1	30.4	29.8	35.6
Swin-T	49.7	48.8	34.4	39.4
AK (130 / 374 imágenes)				
ResNet50	27.3	29.4	45.6	38.8
EffNet-B0	35.5	39.5	40.5	41.3
Swin-T	36.1	40.9	37.9	30.4

En porcentaje, media de 3 semillas (desviaciones en la Tabla V del artículo). Entre paréntesis, imágenes de la clase en el test interno / oficial.

Con 30 épocas el early stopping corta antes del tope y el orden no cambia

	Época		F1 interno			F1 oficial		
	15	30	15	30	Δ	15	30	Δ
ResNet50	13/15	20/23	53.5	54.0	+0.5	51.9	53.0	+1.1
EfficientNet-B0	13/15	16/19	53.6	54.7	+1.1	51.7	52.7	+1.0
Swin-T	10/13	15/18	57.2	60.3	+3.1	57.9	59.1	+1.2

Semilla 0, desde ImageNet, cosine ajustado a 30 épocas (no es una continuación). Época: mejor época / épocas corridas. Δ en pp.

- La ganancia de Swin-T (+3.1) se explica en parte por la semilla: la 0 era la más débil (57.2), y el 60.3 queda 1.4 pp sobre la media de 15 épocas, dentro de su desviación de 1.5.
- ResNet50 tiene su mejor época en la 20: otra señal de subajuste.

Ablación completa: la frecuencia inversa es la mejor o empata en F1 macro del test oficial en los tres modelos

		Test interno		Test oficial		Minoritarias, test interno (P / R)			
	Ponderación	F1 macro	Exact. bal.	F1 macro	Exact. bal.	DF	VASC	SCC	AK
ResNet50	Inversa	53.5	**58.4**	**51.9**	**53.2**	40.4 / 52.8	58.7 / 71.1	29.3 / 45.7	26.8 / 46.2
	Raíz	**53.9**	54.8	51.5	50.2	27.9 / 33.3	68.6 / 63.2	35.1 / 36.2	36.0 / 49.2
	Sin pesos	52.5	48.7	46.6	43.7	75.0 / 16.7	90.9 / 52.6	26.2 / 18.1	38.8 / 34.6
EffNet-B0	Inversa	**53.6**	**53.6**	**51.7**	50.0	50.0 / 36.1	65.7 / 60.5	25.7 / 30.9	40.8 / 37.7
	Raíz	51.8	51.7	**51.7**	**50.6**	33.3 / 22.2	66.7 / 63.2	29.3 / 38.3	36.8 / 30.0
	Sin pesos	51.6	49.2	51.0	48.4	38.9 / 19.4	72.4 / 55.3	33.3 / 27.7	39.4 / 28.5
Swin-T	Inversa	57.2	56.7	**57.9**	**55.7**	62.5 / 27.8	60.5 / 68.4	49.3 / 35.1	36.1 / 36.9
	Raíz	**59.9**	**57.8**	56.7	53.7	50.0 / 33.3	68.6 / 63.2	61.8 / 36.2	41.7 / 36.9
	Sin pesos	56.5	53.3	56.6	53.1	66.7 / 22.2	79.3 / 60.5	46.4 / 34.0	35.0 / 33.1

Semilla 0, en porcentaje. Inversa: $1/n$ (protocolo); raíz: $1/\sqrt{n}$. En negritas, la mejor variante por modelo y métrica global. El 59.9 de Swin-T con raíz iguala a su mejor semilla con frecuencia inversa.

Las tablas y figuras se regeneran desde el repositorio en tres pasos

```
isic2019-benchmark/
  configs/   base + 1 por modelo
  src/isic/  data, models,
             train, evaluate,
             cost, ensemble,
             gradcam
  scripts/   preprocess,
             make_splits,
             run_all.sh,
             make_figures
  results/   splits y métricas
  figures/   figuras, Grad-CAM
  paper/     artículo y slides
```

Reproducir, con los datos en `data/`:

```
uv sync && uv run python scripts/preprocess.py
tmux new-session -d "bash scripts/run_all.sh"
uv run python scripts/make_figures.py
```

- 9 corridas principales: 1 h 22 min en la RTX 5070 Ti
- Splits versionados en `results/splits/`
- Smoke test: `isic.train --smoke`
- Pasos intermedios (evaluate, cost, ensemble, gradcam) en el README

Referencias clave

- Matsoukas et al. (2021): con pesos de ImageNet, ResNet50 y DeiT-S quedan parejos en ISIC 2019
- Aruk, Pacal y Toprak (2026): 15 CNN contra 15 ViT en HAM10000 e ISIC 2019; Swin, la mejor exactitud
- Ayas (2023): Swin Transformer en ISIC 2019, exactitud balanceada de 82.3
- Gessert et al. (2020): ganador de ISIC 2019, ensembles de EfficientNets con metadata, 74.2
- Cassidy et al. (2022): duplicados en ISIC que inflan las métricas si no se agrupa por lesión

Datos: ISIC 2019, licencia CC-BY-NC 4.0, sin fines comerciales. BCN_20000 Dataset: (c) Department of Dermatology, Hospital Clínic de Barcelona. HAM10000 Dataset: (c) by ViDIR Group, Department of Dermatology, Medical University of Vienna; https://doi.org/10.1038/sdata.2018.161. MSK Dataset: (c) Anonymous; https://arxiv.org/abs/1710.05006; https://arxiv.org/abs/1902.03368. Referencias completas en `paper/articulo.pdf`.